

연구 아이디어 정리 보고서

Future Numeric Conflict를 위한 Potential-Based Meta-Heuristic in Numeric Planning

1. 연구 출발점

본 연구의 출발점은 로봇 및 자원 제약 환경에서의 numeric planning을 더 빠르고 효과적으로 수행하는 것이다. 실제 로봇 문제에서는 연료, 배터리, 비용, 용량, 시간과 같은 numeric fluent가 중요한 역할을 하며, 이들 자원은 단순히 독립적으로 존재하지 않고 서로 강하게 결합되어 있다.

초기에는 “numeric effect가 많거나 state space가 커서 planning이 어렵다”는 가설을 고려했지만, 실험과 논의를 통해 더 구체적인 현상이 관찰되었다.

자원 제약이 매우 느슨한 경우에는 많은 행동 순서가 feasible하기 때문에 planner가 쉽게 해를 찾을 수 있다. 반대로 자원 제약이 매우 강한 경우에는 infeasible한 branch가 초기에 빠르게 제거되기 때문에 역시 상대적으로 쉽게 풀린다. 가장 어려운 경우는 자원 제약이 중간 수준일 때이다. 이 경우 초반에는 여러 branch가 모두 feasible해 보이지만, resource consumption, fluent coupling, action ordering, shared-resource competition이 누적되면서 비교적 깊은 지점에서 infeasibility가 드러난다.

즉 관찰된 난이도 패턴은 대략 다음과 같다.

easy → hard → easy

이 현상은 단순히 state space 크기보다, locally plausible하지만 globally infeasible한 branch가 얼마나 오래 살아남는지가 planning difficulty에 중요한 영향을 줄 수 있음을 시사한다.

2. 기존 numeric heuristic의 trade-off

Metric-FF와 같은 relaxation 기반 heuristic은 계산이 매우 빠르고 coverage가 높다. 특히 실제 실험에서 Metric-FF는 다른 planner들이 timeout이 발생하는 상황에서도 매우 짧은 시간 안에 plan을 찾는 경우가 있었다. 다만 이러한 plan은 비효율적일 수 있으며, 이는 Metric-FF가 numeric interaction을 강하게 relaxation하기 때문이다.

Metric-FF는 delete relaxation과 monotonic numeric relaxation을 기반으로 relaxed planning graph를 구성한다. 이 과정에서 resource decrease나 unfavorable numeric effects가 악화되거나 무시될 수 있다. 따라서 실제로는 fuel, budget, capacity 등의 누적 소비 때문에 infeasible한 경로가 relaxed problem에서는 여전히 feasible하게 보일 수 있다.

반대로 interval-based heuristic, Numeric LM-Cut, LP-RPG, Numeric CEGAR, learned numeric heuristic 등은 numeric structure를 더 강하게 반영할 수 있다. 그러나 이러한 strong heuristic은 일반적으로 heuristic evaluation 자체의 계산 비용이 더 크다.

따라서 핵심 trade-off는 다음과 같다.

Cheap but weak heuristic

대

Strong but expensive numeric heuristic

즉 더 informed한 heuristic이 항상 더 빠른 planner를 의미하지 않는다. 전체 planning time은 대략

$$T_{\text{total}} \approx N_{\text{expansion}} \times T_{\text{heuristic}} + T_{\text{other}}$$

로 볼 수 있기 때문에, node expansion을 줄이더라도 per-node heuristic evaluation cost가 너무 크면 전체 planning time은 오히려 증가할 수 있다.

3. 왜 hard regime이 어려운가

초기에 고려한 문제는 다음과 같은 numeric interaction이었다.

1. numeric transition이 현재 state에 의존하는 경우
2. fluent 간 coupling이 강한 경우
3. 그 결과 feasibility가 action ordering에 강하게 의존하는 경우
4. 여러 action이 동일한 resource를 경쟁적으로 소비하는 경우

이 조건들이 강해지면 특정 branch는 초반에는 충분히 가능해 보이지만, 이후에 resource가 누적 소비되면서 늦게 실패한다.

따라서 hard regime의 핵심은 단순한 “constraint가 많다”가 아니라 다음과 같이 정리할 수 있다.

Many locally feasible branches survive until delayed numeric conflicts appear.

4. delayed infeasibility를 미리 아는 것은 왜 어려운가

가장 직접적인 해결책은 현재 선택이 미래의 numeric infeasibility를 유발할지 미리 판단하는 것이다.

하지만 이를 정확히 판단하려면 이후의 resource trajectory와 action ordering을 상당 부분 계산해야 한다. 즉 “이 action을 지금 선택하면 몇 단계 뒤 어떤 numeric conflict가 발생하는가?”를 정확히 알려면 사실상 미래 plan을 상당 부분 미리 풀어야 한다.

따라서 heuristic을 빠르게 만들기 위해 미래를 정확히 계산하려 하면, heuristic 단계에서 다시 원래 planning problem과 유사한 계산 부담이 발생한다.

일반적인 numeric planning에서 exact feasibility reasoning은 본질적으로 어려우며, 표현력이 높은 일부 numeric planning fragment에서는 plan existence 자체도 결정불가능한 것으로 알려져 있다. 따라서 future numeric conflict를 완전히 계산하기보다는, 이를 저비용으로 근사하는 prior가 필요하다.

5. instance-level easy-hard-easy에서 state-level difficulty로

easy-hard-easy는 전통적으로 instance-level constrainedness와 관련된 현상으로 다뤄져 왔다. 그러나 본 연구에서 heuristic gating을 state-level로 수행하려면 한 인스턴스 안에서도 difficulty가 상태마다 달라질 수 있다는 가설이 필요하다.

이 가설은 resource-consuming planning에서 자연스럽다. 동일한 problem 안에서도 초기에는 resource가 충분해 loose한 상태일 수 있지만, search가 진행되면서 resource가 감소하면 intermediate regime으로 이동할 수 있다. 더 나아가 특정 branch에서는 거의 infeasible한 tight regime으로 들어갈 수 있다.

따라서 constrainedness를 단순한 instance-level 상수로만 보지 않고,

$$\kappa(s)$$

와 같이 state-dependent local constrainedness로 해석할 수 있다.

이 관점에서는 모든 state에서 동일한 강도의 heuristic reasoning을 수행하는 것이 비효율적일 수 있다. 어떤 state에서는 Metric-FF 수준의 cheap reasoning이면 충분하고, 어떤 state에서는 strong numeric heuristic이 필요할 수 있다.

6. 단순 local constrainedness만으로 충분한가

가장 단순한 gating signal은 남은 resource와 relaxed demand의 비율일 수 있다.

예를 들어

$$\kappa(s) \approx \frac{\text{remaining resource}}{\text{estimated future demand}}$$

와 같은 cheap signal을 생각할 수 있다.

하지만 이 방식에는 구조적 한계가 있다. future demand 자체를 Metric-FF나 relaxed plan에서 얻는다면, 그 estimate는 이미 ordering과 resource competition을 relaxation한 결과이다.

즉 cheap relaxation이 가장 크게 틀리는 경우는 바로 다음과 같은 경우다.

현재는 slack이 충분해 보이지만, 실제로는 ordering과 competition 때문에 이후에 실패하는 경우

따라서 local resource slack만으로는 relaxation의 사각지대를 다시 놓칠 가능성이 있다.

이로부터 보다 정확한 연구 질문이 나온다.

Can we cheaply predict where relaxed numeric reasoning will become misleading before the conflict appears?

7. 연구의 핵심 가설: feasibility prior

본 연구의 핵심은 새로운 numeric heuristic을 직접 만드는 것이 아니라, cheap relaxation이 미래에 잘못된 방향으로 search를 유도할 가능성을 나타내는 저비용 prior를 구성하는 것이다.

이 prior는 여러 방식으로 얻을 수 있다.

- domain structure에서 직접 계산되는 feasibility indicator
- resource slack, bottleneck margin 등의 hand-crafted signal
- 짧은 lookahead 또는 제한적 feasibility check
- 사람의 고수준 전략
- 별도의 fine-tuning 없이 LLM이 생성한 semantic strategy

따라서 사람이나 LLM은 연구의 필수 전제가 아니다. 가장 근본적인 문제는 future numeric conflict를 싸게 예측하는 것이다.

사람이나 LLM을 사용하는 이유는 정확한 future trajectory를 계산하지 않고도 domain semantics를 통해 유용한 전략적 prior를 제공할 가능성이 있기 때문이다.

8. Potential heuristic for heuristic

초기 방법론 가설은 이러한 prior를 state potential의 형태로 표현하는 것이다.

기존 potential heuristic은 일반적으로 state에 potential을 부여하여 goal distance를 추정한다. 예를 들어

$$h(s) = \sum_i \phi_i(s_i)$$

또는 higher-dimensional interaction을 포함하여

$$h(s) = \sum_i \phi_i(s_i) + \sum_{i,j} \phi_{ij}(s_i, s_j) + \dots$$

와 같이 정의할 수 있다.

본 연구에서는 potential을 직접 cost-to-go heuristic으로 사용하는 것이 아니라, heuristic을 위한 heuristic, 즉 meta-level signal로 사용하는 것을 고려한다.

이를

$$P(s)$$

라고 하면, $P(s)$ 는 “goal까지 얼마나 남았는가?”를 직접 나타내기보다 다음과 같은 의미를 갖는다.

현재 state에서 cheap heuristic을 계속 신뢰해도 되는가?

또는

이 state에서 strong numeric reasoning을 호출할 가치가 있는가?

즉 potential은 future numeric conflict에 대한 prior를 state-level scalar 또는 structured signal로 변환하는 역할을 한다.

Future conflict prior $\rightarrow$ State potential $P(s) \rightarrow$ Heuristic selection / allocation

9. Heuristic gating

가장 단순한 구현 가설은 state potential을 이용한 heuristic gating이다.

cheap heuristic을

$$h_{\text{cheap}}$$

strong numeric heuristic을

$$h_{\text{strong}}$$

이라고 하면,

$$P(s) < \tau \Rightarrow h_{\text{cheap}}(s)$$

$$P(s) \geq \tau \Rightarrow h_{\text{strong}}(s)$$

와 같이 strong reasoning을 선택적으로 호출할 수 있다.

여기서 h_{cheap} 은 Metric-FF가 될 수 있고, h_{strong} 은 다음과 같이 교체 가능한 module로 둘 수 있다.

- interval-based numeric heuristic
- Numeric LM-Cut
- LP-RPG
- abstraction-based heuristic
- Numeric CEGAR-derived heuristic
- learned GNN numeric heuristic

따라서 제안 방법의 핵심은 새로운 h_{strong} 을 만드는 것이 아니라,

strong numeric reasoning을 언제 사용할지 결정하는 것

이다.

10. Metric-FF를 gating 이후에도 어떻게 사용할 것인가

gating 구조를 사용하면 strong region에서 Metric-FF를 완전히 버릴지 여부는 세부 설계 문제로 남는다.
가능한 구조는 다음과 같다.

Hard switch:

$$P(s) < \tau \Rightarrow h_{\text{FF}}$$

$$P(s) \geq \tau \Rightarrow h_{\text{strong}}$$

Gated augmentation:

Metric-FF는 항상 계산하고, 필요한 state에서만 strong heuristic을 추가한다.

Role separation:

- strong numeric heuristic: node ordering
- Metric-FF: helpful action / preferred operator generation

이 부분은 핵심 연구주제라기보다 이후 방법론 세부 설계로 볼 수 있다.

11. 사람 / LLM semantic strategy의 역할

사람 또는 LLM의 high-level strategy를 사용하는 경우, LLM을 search 중 매 state마다 호출하는 구조는 적절하지 않다.

더 자연스러운 구조는 다음과 같다.

$$\text{Domain / Problem} \xrightarrow{\text{LLM once}} \text{High-level semantic strategy}$$

그 후 strategy를 planner가 빠르게 평가 가능한 state-level potential로 변환한다.

$$\text{Semantic strategy} \rightarrow \text{Strategy features} \rightarrow P(s)$$

search 중에는 LLM을 다시 호출하지 않고 $P(s)$ 만 계산한다.

이 경우 LLM의 역할은 online heuristic evaluator가 아니라,

zero-shot strategy generator / heuristic designer

이다.

그러나 LLM은 연구의 필수 구성요소가 아니다. 단순한 feasibility estimator가 semantic prior보다 더 잘 작동한다면, 연구는 LLM 없이 numeric phase-transition / selective reasoning framework로도 성립할 수 있다.

12. 기존 연구와의 계보

12.1 Numeric relaxation Metric-FF는 delete relaxation과 monotonic numeric relaxation을 이용해 빠른 heuristic evaluation을 제공한다. 이후 interval relaxation, repetition reasoning, numeric subgoal relaxation 등은 numeric reachability를 더 정교하게 모델링하려 했다.

12.2 Stronger numeric reasoning LP-RPG는 resource flow를 LP/MIP로 모델링하여 기존 relaxed planning graph가 놓치는 consumable resource competition을 보완한다.

Numeric LM-Cut은 linear numeric planning에서 admissible lower bound를 구성한다.

Numeric CEGAR는 coarse abstraction에서 시작하여 spurious behavior를 counterexample-guided refinement로 제거한다.

이러한 방법들은 더 강한 numeric information을 제공하지만 계산 overhead가 증가할 수 있다.

12.3 Heuristic computation cost Classical heuristic search에서는 heuristic informativeness뿐 아니라 heuristic computation cost가 중요하다는 문제가 오래전부터 논의되었다.

Selective Max는 state마다 어떤 heuristic을 계산할지 online learning으로 결정하여 heuristic cost와 search reduction 사이의 trade-off를 다룬다.

Dynamic Heuristic Selection은 search dynamics를 이용해 expansion 과정에서 사용할 heuristic을 동적으로 선택한다.

Lazy / deferred evaluation은 heuristic evaluation을 node generation 시점이 아니라 expansion 시점까지 미루어 불필요한 계산을 줄인다.

Alternation queue / multi-queue search는 서로 다른 heuristic을 여러 queue에서 병렬적으로 활용한다.

12.4 Numeric heuristic combination Numeric planning에서도 novelty heuristic, multi-queue search, portfolio를 통해 여러 heuristic을 결합하는 방법이 제안되었다.

이러한 연구는 여러 heuristic을 함께 사용하는 것이 유용함을 보여주지만, future numeric conflict 자체를 사전 예측하여 state별로 strong reasoning을 호출하는 문제와는 차이가 있다.

12.5 Learned numeric heuristic 최근에는 GNN을 이용해 numeric planning에서 domain-dependent heuristic을 학습하는 연구도 등장했다.

이러한 learned heuristic은 강한 h_{strong} 후보로 활용될 수 있다.

본 연구는 learned heuristic 자체를 새롭게 만드는 것이 아니라, 해당 heuristic을 언제 호출할지 결정하는 meta-level mechanism에 초점을 둔다.

12.6 LLM-generated heuristic 2025년 이후에는 LLM을 이용해 domain-specific planning heuristic을 자동 생성하는 연구가 등장하고 있다.

본 연구와의 차이는 heuristic function 자체를 직접 생성하는 데 목적을 두기보다,

future numeric conflict에 대한 semantic prior

를 생성하고,

이를

state-level heuristic allocation

에 사용한다는 점에 있다.

13. Related Work 상의 positioning

관련 연구 계보는 다음과 같이 요약할 수 있다.

Numeric relaxation → Stronger numeric reasoning → Heuristic computation cost problem → Selective / dynar

본 연구는 마지막 지점에 위치한다.

기존 selector는 주로 heuristic performance, search dynamics, online statistics를 이용해 어느 heuristic을 계산할지 결정한다.

본 연구는 다음 질문을 다룬다.

Can we predict where a cheap numeric relaxation will become misleading before the conflict is explicitly encountered?

이를 위해 future conflict에 대한 prior를 state potential로 표현하고, 해당 potential을 heuristic-for-heuristic으로 사용하여 strong numeric reasoning을 필요한 상태에 선택적으로 배분한다.

14. Potential heuristic과 cost partitioning

Potential heuristic은 대전략이나 prior를 state-space의 preference landscape로 표현하는 데 유용한 후보이다.

다만 현재 단계에서 본 연구를 “potential heuristic을 이용한 cost partitioning”이라고 직접 정의하는 것은 이른다.

일반적인 cost partitioning은 operator cost를 여러 heuristic에 분배하여 admissible heuristic combination을 만드는 문제이다.

반면 현재의 핵심은

state potential을 이용한 heuristic computation allocation

이다.

향후 state-dependent cost allocation이나 admissibility-preserving heuristic combination까지 확장한다면, strategy-conditioned cost partitioning과 같은 방향으로 발전시킬 수 있다.

15. 현재 연구 contribution 가설

첫째, resource-coupled numeric planning에서 planning difficulty가 단순한 numeric dimension보다 delayed numeric infeasibility와 resource competition에 크게 영향을 받는다는 점을 분석한다.

둘째, cheap relaxation과 strong numeric reasoning 사이의 quality-computation trade-off를 state-level selective reasoning 문제로 재정의한다.

셋째, future numeric conflict에 대한 저비용 prior를 state potential로 표현하고, 이를 heuristic-for-heuristic으로 사용하여 strong numeric heuristic computation을 필요한 상태에 선택적으로 할당하는 framework를 제안한다.

넷째, prior의 source는 특정 방식에 제한하지 않고, hand-crafted feasibility signal, human strategy, 또는 zero-shot LLM semantic strategy 등으로 확장 가능하게 구성한다.

다섯째, h_{strong} 을 특정 heuristic에 고정하지 않고 여러 strong numeric heuristic을 plug-in 형태로 사용할 수 있도록 하여 heuristic-agnostic한 meta-reasoning framework를 지향한다.

16. 현재 가장 중요한 연구 질문

How can we cheaply predict delayed numeric infeasibility before it is explicitly encountered?

보다 구체적으로는,

Can a state potential predict when cheap relaxation becomes misleading?

그리고,

Can this prediction selectively allocate expensive numeric reasoning and improve wall-clock planning efficiency?

이다.

17. 앞으로 확인해야 할 핵심 사항

현재 연구주제는 충분히 compact해졌지만, 몇 가지 핵심 가설은 이후 반드시 검증되어야 한다.

첫째, strong numeric heuristic이 모든 state에서 고르게 유용한 것이 아니라, 특정 state 또는 regime에서 집중적으로 유용한지 확인해야 한다.

둘째, local resource tightness와 같은 단순한 cheap signal만으로 strong heuristic 필요성을 충분히 예측할 수 있는지 확인해야 한다.

셋째, semantic / structural prior가 단순 slack 기반 signal보다 ordering, competition, future bottleneck을 더 잘 포착하는지 확인해야 한다.

넷째, gating signal의 계산 비용은 cheap heuristic에 비해 충분히 작아야 한다.

다섯째, 최종 평가는 node expansion뿐 아니라 heuristic evaluation time과 total wall-clock time을 함께 봐야 한다.

18. 한 문장 요약

본 연구는 resource-coupled numeric planning에서 늦게 드러나는 numeric infeasibility를 저비용의 state potential로 미리 예측하고, 이를 heuristic-for-heuristic으로 사용해 cheap relaxation과 strong numeric reasoning 사이의 계산 자원을 상태별로 선택적으로 배분함으로써 planning efficiency를 개선하는 방법을 연구한다.